

# 自然语言处理第二次作业

陈远腾 2020k8009929041

## 一、环境搭建

- 1.新建conda环境
- 2.安装tensorflow\_gpu
- 3.所需其它依赖库
- 4.nltk\_data安装

## 二、实验过程

- 1.数据处理
- 2.模型搭建
  - (1) layers.embedding层
  - (2) FNN model
  - (2) RNN model
  - (3) LSTM model
  - (4) 模型编译
  - (5) 模型训练
- 3.结果输出
  - (1) 词向量提取+计算距离矩阵
  - (2) 输出结果
    - [1] FNN
    - [2] RNN
    - [3] LSTM

## 三、实验结果

## 一、环境搭建

---

### 1.新建conda环境

```
conda create -n NLP python=3.7 anaconda
conda activate NLP
```

### 2.安装tensorflow\_gpu

(安装cuda+cudnn见网上教程)

```
conda install tensorflow
```

### 3.所需其它依赖库

- re
- argparse
- csv
- numpy
- nltk

## 4.nltk\_data安装

nltk是一套基于python的自然语言处理工具集，主要功能如下：

语言处理任务	NLTK 模块	功能描述
获取和处理语料库	<code>nltk.corpus</code>	语料库和词典的标准化接口
字符串处理	<code>nltk.tokenize</code> , <code>nltk.stem</code>	分词，句子分解提取主干
搭配发现	<code>nltk.collocations</code>	t-检验，卡方，点互信息 PMI
词性标识符	<code>nltk.tag</code>	n-gram, backoff, Brill, HMM, TnT
分类	<code>nltk.classify</code> , <code>nltk.cluster</code>	决策树，最大熵，贝叶斯，EM, k-means
分块	<code>nltk.chunk</code>	正则表达式, n-gram, 命名实体
解析	<code>nltk.parse</code>	图表，基于特征，一致性，概率，依赖
语义解释	<code>nltk.sem</code> , <code>nltk.inference</code>	$\lambda$ 演算，一阶逻辑，模型检验
指标评测	<code>nltk.metrics</code>	精度，召回率，协议系数
概率与估计	<code>nltk.probability</code>	频率分布，平滑概率分布
应用	<code>nltk.app</code> , <code>nltk.chat</code>	图形化的关键词排序，分析器，WordNet查看器，聊天机器人
语言学领域的工作	<code>nltk.toolbox</code>	处理 SIL 工具箱格式的数据 <a href="http://www.asialee_bird.net/">http://www.asialee_bird.net/</a>

nltk库的安装比较麻烦，所以这里单独说明：

首先需要 `pip install nltk`, 然后需要下载nltk具体的packages：

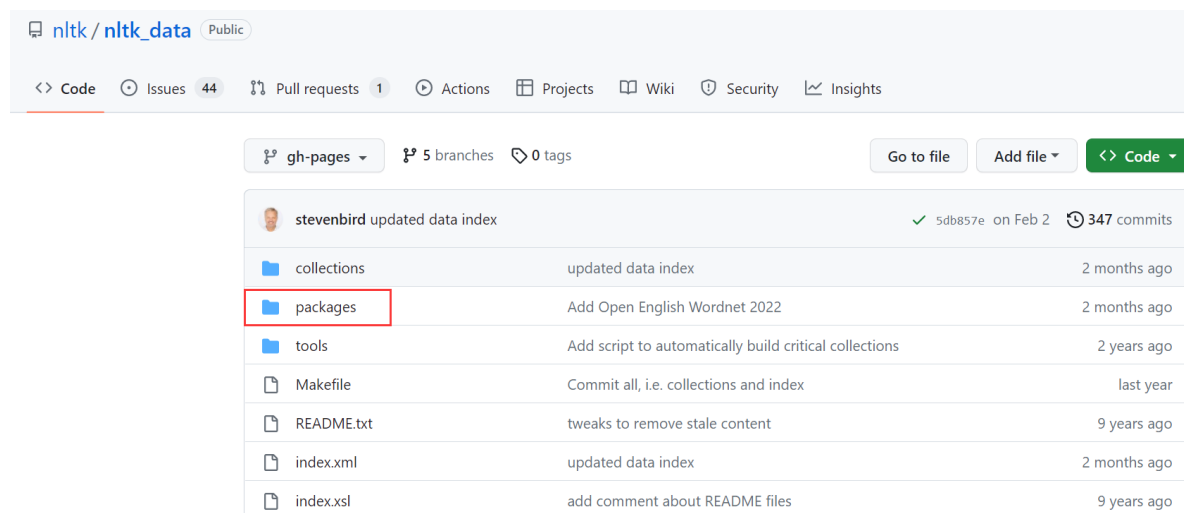
官方给出的方法是先进入python环境，然后运行：

```
import nltk
nltk.download()
```

但实测这样很难下载成功。替代方案是去github上的nltk主页

[NLTK\\_github主页](#)

下载其中的packages文件夹，下载后将其解压在D盘的根目录下，并将文件夹改名为nltk\_data



安装成功的检测方法：

```

Anaconda Prompt (Anaconda_setup) - python

(base) C:\Users\cyt>conda activate malning

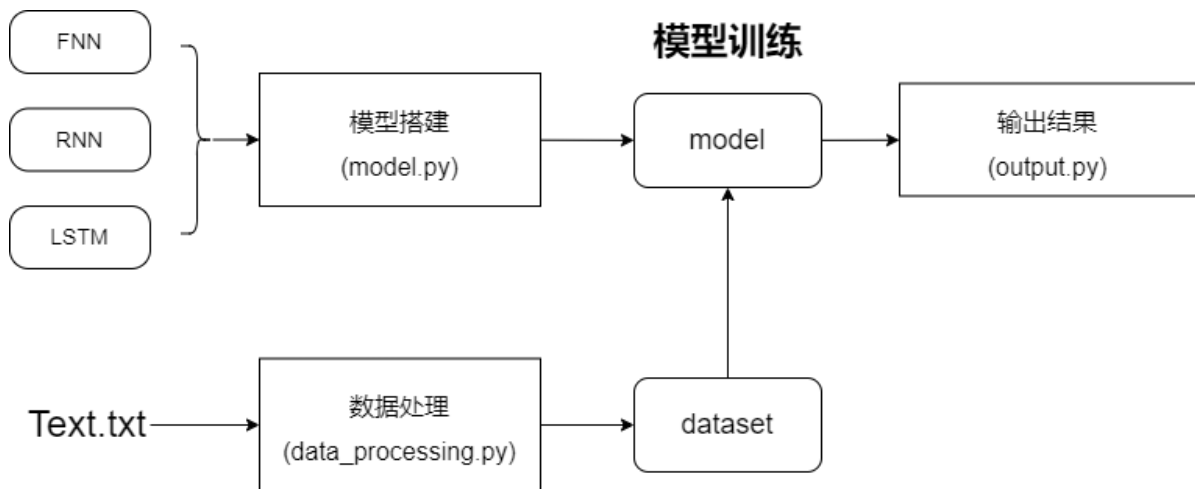
(malning) C:\Users\cyt>python
Python 3.7.0 (default, Jun 28 2018, 08:04:48) [MSC v.1912 64 bit (AMD64)] :: Anaconda, Inc. on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> import nltk
>>> from nltk.book import *
*** Introductory Examples for the NLTK Book ***
Loading text1, ..., text9 and sent1, ..., sent9
Type the name of the text or sentence to view it.
Type: 'texts()' or 'sents()' to list the materials.
text1: Moby Dick by Herman Melville 1851
text2: Sense and Sensibility by Jane Austen 1811
text3: The Book of Genesis
text4: Inaugural Address Corpus
text5: Chat Corpus
text6: Monty Python and the Holy Grail
text7: Wall Street Journal
text8: Personals Corpus
text9: The Man Who Was Thursday by G . K . Chesterton 1908
>>>
```

正常显示出text1-9则说明nltk\_data安装成功。

(如果安装还是不成功，可以参考csdn，nltk\_data安装的教程很多)

## 二、实验过程


实验过程主要分为数据处理、模型训练和结果分析及输出三部分：



下面依次介绍这三部分内容：

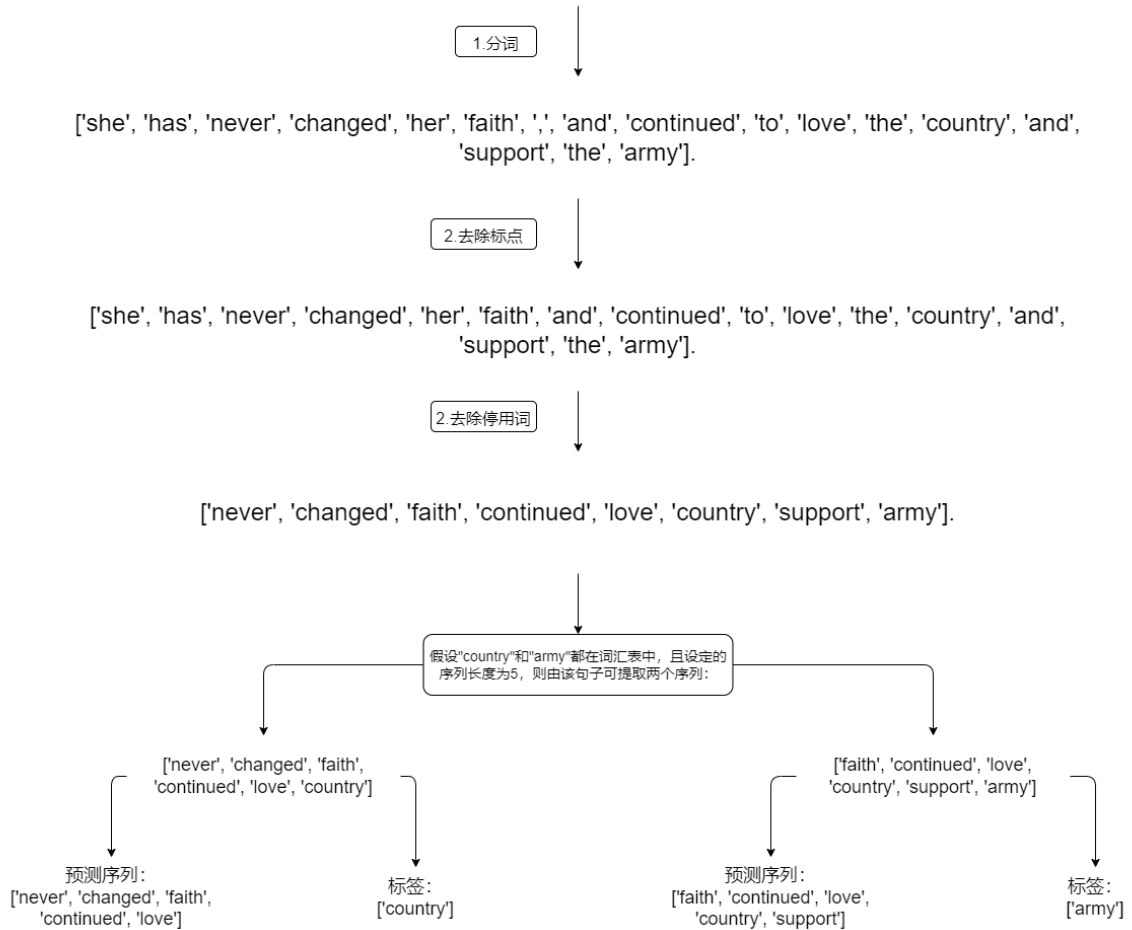
### 1.数据处理

数据处理模块的输入为原始的英文文本，输出为序列化的dataset：



以处理以下文本为例：

she has never changed her faith, and continued to love the country and support the army.



实际处理中，我们首先需要将词汇表中的每一个词映射为一个值，编码后才能进行训练，如下：

```
In [17]: word_index = dict((word, main_keys.index(word)+1) for word in main_keys)
word_index
```

```
Out[17]: {'china': 1,
'people': 2,
'taiwan': 3,
'development': 4,
'said': 5,
'chinese': 6,
'countries': 7,
'two': 8,
'also': 9,
'new': 10,
'us': 11,
'economic': 12,
'relations': 13,
'united': 14,
'states': 15,
'party': 16,
'government': 17,
'one': 18,
'must': 19,
'military': 20,
```

依据word\_index，将序列中的每个词转换为对应数字，词汇表外的词映射为0。

最终经过以上过程处理，得到6w+条训练序列：

```
In [38]: tf_data = tf.constant(data)
tf_label = tf.constant(label)
```

```
In [39]: tf_data.shape
```

```
Out[39]: TensorShape([62646, 5])
```

```
In [40]: tf_label.shape
```

```
Out[40]: TensorShape([62646])
```

这些序列与标签后续将送入模型进行训练。

## 2.模型搭建

本次实验中，基于tensorflow2.0搭建了FNN, RNN, LSTM三个model，这三个网络的第一层均为embedding层，输出层均为 (Num\_keys + 1)个单元的Dense层，区别仅在于中间层为：

- FNN: Flatten() + Dense(Num\_kernels)
- RNN: SimpleRNN(Num\_kernels)
- LSTM: LSTM(Num\_kernels)

## (1) layers.embedding层

由于这三个模型中的第一层均为embedding层，且这是实现词向量嵌入的关键，故我们单独进行介绍：

```
#layers定义
tf.keras.layers.Embedding(
    input_dim, output_dim, embeddings_initializer='uniform',
    embeddings_regularizer=None, activity_regularizer=None,
    embeddings_constraint=None, mask_zero=False, input_length=None, **kwargs
)
```

参数说明：(介绍中省略了我们使用默认值的参数)

- input\_dim：词汇表的大小，即最大整数索引+1。
- output\_dim：稠密嵌入的维数。
- input\_length：输入序列的长度。

输入：(batch\_size, input\_length)的二维张量。

输出：(batch\_size, input\_length, output\_dim)的三维张量。

同时最重要的是，embedding层的参数即为最终欲求的词向量，

其形状为(input\_dim, output\_dim)，也即(词汇表长度 x 词向量嵌入维数)。

故在训练model后，我们只要提取embedding层的weights即可得到最终的词向量。

## (2) FNN model

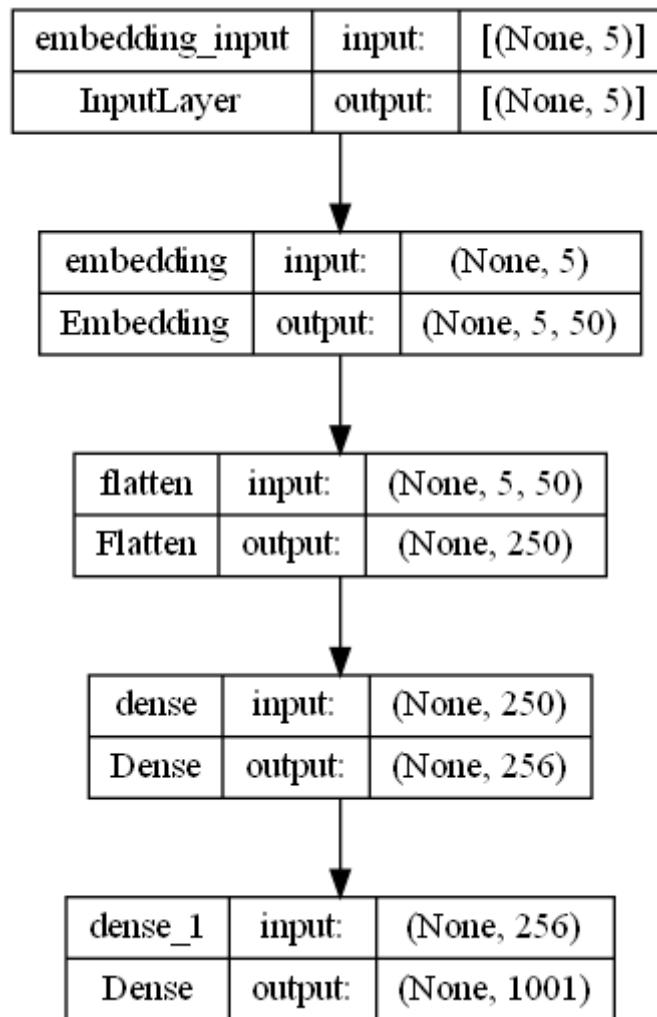
```
# model1: FNN model
def Build_FNN_model(Num_keys, Vector_len, Input_len, Num_kernels):
    """
    :param Num_keys: 词汇表长度
    :param Vector_len: 单个词向量的长度
    :param Input_len: 单个输入向量的长度
    :param Num_kernels: Hidden Layer Dense层的核数
    :return: model
    """

    model = keras.Sequential()
    # Embedding层将Num_keys个词汇嵌入到Num_keys个长度为Vector_Len的向量中
    model.add(layers.Embedding(Num_keys+1, Vector_len, input_length=Input_len))
    # FNN模型需要先将Embedding的输入结果铺平（将向量展开）
    model.add(layers.Flatten())
    """
    Embedding_output: (Batch_size , Input_len , Vector_len))
                        |
                        | layers.Flatten()
                        v
    Flatten_output:   (Batch_size , (Input_len x Vector_len))
    """

    #添加隐藏层
    model.add(layers.Dense(Num_kernels))
    #输出层，多分类激活函数使用softmax
    model.add(layers.Dense(Num_keys+1, activation='softmax'))
```

```
return model
```

利用pydot绘图如下：



值得注意的有两点：

- 一是这里的词汇表长度为( $\text{Num\_keys} + 1$ )的原因是“UNK”也在词汇表中。
- 在FNN模型中，由于后续没有处理序列的RNN单元，故需要一个Flatten层将输入的向量序列铺平，才能够输入到后续的Dense层中。

## (2) RNN model

```
# model2: RNN model
def Build_RNN_model(Num_keys, Vector_len, Input_len, Num_kernels):
    """
    :param Num_keys: 词汇表长度
    :param Vector_len: 单个词向量的长度
    :param Input_len: 单个输入向量的长度
    :param Num_kernels: RNN层的核数
    :return: model
    """

    model = keras.Sequential()
    # Embedding层将Num_keys个词汇嵌入到Num_keys个长度为Vector_Len的向量中
    model.add(layers.Embedding(Num_keys+1, Vector_len, input_length=Input_len))
```

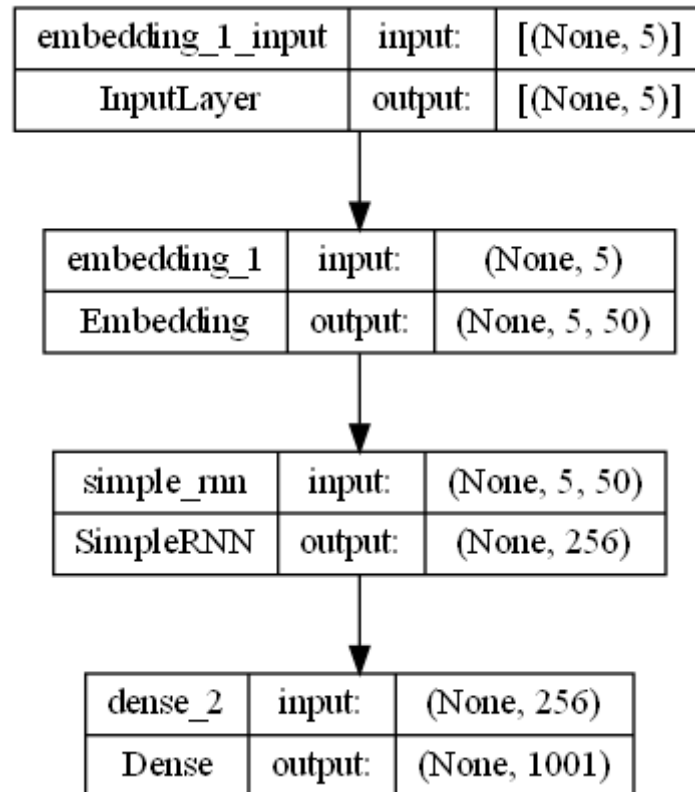
```

#添加RNN层
model.add(layers.SimpleRNN(Num_kernels))
#输出层，使用"softmax"作为激活函数
model.add(layers.Dense(Num_keys+1, activation='softmax'))

return model

```

利用pydot绘图如下:



### (3) LSTM model

```

# model13: LSTM model
def Build_LSTM_model(Num_keys, Vector_len, Input_len, Num_kernels):
    """
    :param Num_keys: 词汇表长度
    :param Vector_len: 单个词向量的长度
    :param Input_len: 单个输入向量的长度
    :param Num_kernels: LSTM层的核数
    :return: model
    """

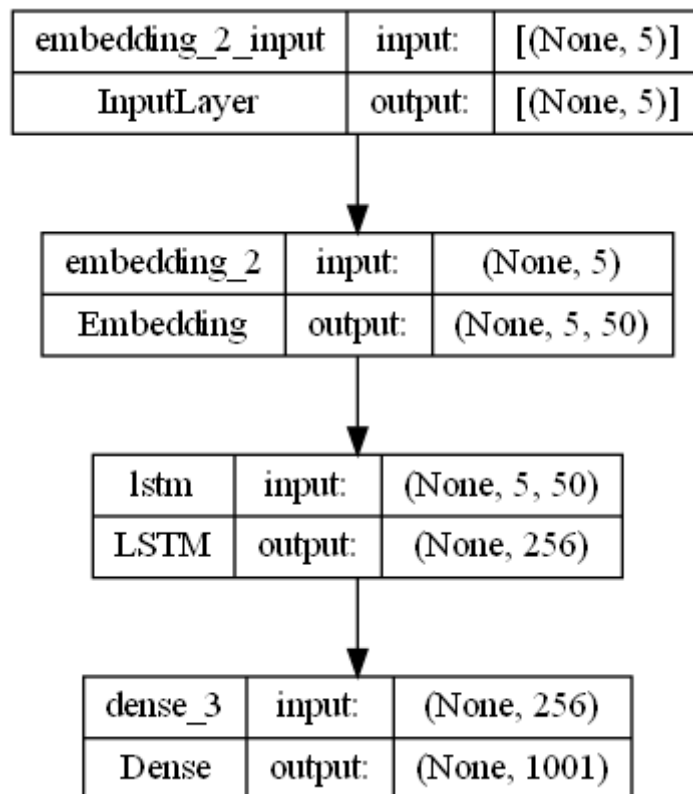
    model = keras.Sequential()
    #Embedding层将Num_keys个词汇嵌入到Num_keys个长度为Vector_Len的向量中
    model.add(layers.Embedding(Num_keys+1, Vector_len, input_length =
Input_len))
    #LSTM层
    model.add(layers.LSTM(Num_kernels))
    #输出层，使用"softmax"作为激活函数
    model.add(layers.Dense(Num_keys+1, activation='softmax'))

    return model

```



利用pydot绘图如下：



#### (4) 模型编译

```
# compile model
# 由于三个模型使用的优化器、损失函数及评估方法相同，故定义同一个编译函数

def Compile_model(model):
    """
    优化器: adam
    损失函数: 交叉混合熵
    (由于label是直接编码而非独热码，故使用"sparse")
    评估: acc

    :param model: 搭建的模型
    :return: 编译后的模型
    """

    model.compile(optimizer='adam',
                  loss='sparse_categorical_crossentropy',
                  metrics=['acc'])

    return model
```

- 优化器: Adam优化器
- 损失函数: 'sparse\_categorical\_crossentropy', 因为我们这里的标签采取的是直接编码而非独热码，所以需要使用"sparse"。
- 评价指标: accuracy

## (5) 模型训练

```
# train model
def Train_model(model, tf_data, tf_label, epochs, batch_size, validation_split):
    """

    :param model: 编译过的模型
    :param tf_data: 训练数据(向量序列)
    :param tf_label: 标签集
    :param epochs: 训练轮数
    :param batch_size: batch_size
    :param validation_split: 训练集/测试集划分 (0.2意味20%训练集)
    :return: 训练过的模型
    """

    model.fit(tf_data, tf_label, epochs=epochs, batch_size=batch_size,
              validation_split=validation_split)
    return model
```

## 3.结果输出

前面我们提到过，训练过后的model的embedding层的weights即为词汇表的词向量。

### (1) 词向量提取+计算距离矩阵

- step1: 将embedding层的weights提取出来并与词汇表结合制作字典。

```
In [110]: lstm_embedding_result




Out[110]: {'china': array([ 1.23033307e-01, -1.76221907e-01, -2.49400765e-01, -6.26076534e-02,
 2.27359943e-02, -1.51980892e-01, -6.58191293e-02, -2.50297993e-01,
-6.76068440e-02, 2.39660051e-02, 1.21641412e-01, 6.81995042e-03,
 2.50610970e-02, -3.56110036e-01, 1.76840827e-01, 1.42511232e-02,
-5.32127246e-02, 1.70633167e-01, 1.81772023e-01, -3.86770517e-02,
 1.19461015e-01, 1.12730205e-01, 5.54878917e-03, -7.91999251e-02,
 2.30967477e-02, 3.51498311e-04, -1.31002128e-01, -8.02434757e-02,
 5.28136082e-02, 2.48667300e-02, 4.21605632e-03, -1.03693001e-01,
-1.53431892e-01, -1.09796181e-01, 1.92664772e-01, -2.19189480e-01,
 6.21301271e-02, 4.11143573e-03, -1.16415761e-01, -3.36676724e-02,
 1.65973127e-01, 7.60267898e-02, 2.26801798e-01, 6.51468933e-02,
-2.38256544e-01, -9.80236605e-02, -1.81193855e-02, 4.11388464e-02,
-1.09785601e-01, 1.29148334e-01], dtype=float32),
'people': array([ 0.02905458, 0.02239565, 0.03787962, -0.10867328, 0.10307689,
-0.00963774, -0.0877937, 0.07029191, -0.00913368, -0.10487436,
 0.01276105, 0.11686436, 0.02419597, 0.10166058, -0.02140475,
 0.17028385, -0.00392517, -0.05497375, 0.00594822, 0.01949847,
 0.06495836, 0.10802469, 0.01538396, -0.02219599, 0.02749203,
 0.15532522, 0.01753022, -0.0939441, 0.12369754, 0.130121,
 0.06217542, -0.03164027, 0.06871128, 0.11664812, -0.09293687,
```

- step2: 制作距离矩阵，取两个词的词向量之间的欧氏距离作为两个词之间的距离

```
In [124]: lstm_distance

Out[124]: array([[0., 1.13067436, 1.95203602, ..., 1.14834356, 1.24748445,
 1.1194073 ],
 [1.13067436, 0., 1.92664671, ..., 1.12526202, 1.07407403,
 0.82713801],
 [1.95203602, 1.92664671, 0., ..., 1.76805532, 1.86803877,
 1.8742038 ],
 ...,
 [1.14834356, 1.12526202, 1.76805532, ..., 0., 1.22868037,
 0.91859883],
 [1.24748445, 1.07407403, 1.86803877, ..., 1.22868037, 0.,
 1.06184256],
 [1.1194073, 0.82713801, 1.8742038, ..., 0.91859883, 1.06184256,
 0. ]])
```



 FNN	2023/4/23 20:36	XLS 工作表	843 KB
 LSTM	2023/4/23 20:36	XLS 工作表	850 KB
 RNN	2023/4/23 20:36	XLS 工作表	846 KB

这里我们随机取词汇表中10个词，对比三个模型得到的最相似20词结果，如下：

word	FNN	RNN	LSTM
government	['failed', 'developing', 'positive', 'members', 'situation', 'cpc', 'still', 'strengthening', 'department', 'using', 'operation', 'united', '1999', 'principle', 'order', 'essence', 'able', 'premier', 'outside', 'million']	['socialist', 'made', 'members', 'bush', 'young', 'allround', 'failed', 'situation', 'officers', 'china', 'united', 'issue', 'views', 'using', 'success', 'show', 'province', 'far', 'development', 'present']	['hard', 'rate', 'million', 'regional', 'goal', 'hightech', 'sea', 'premier', 'talks', 'maintain', 'best', 'job', 'political', 'essence', 'reports', 'develop', 'lot', 'anniversary', 'members', 'made']
control	['policy', 'failed', 'beginning', 'high', 'defense', 'assistance', 'research', 'promote', 'general', 'form', 'productive', 'progress', 'best', 'zhang', 'put', 'come', 'fine', 'dialogue', 'committee', 'process']	['understanding', 'failed', '3', 'words', 'zemin', 'stressed', 'direction', 'democracy', 'committees', 'present', 'made', 'growth', 'internal', 'department', 'across', 'concerned', 'exchange', 'hard', 'situation', 'socialist']	['natural', 'maintained', 'another', 'possible', 'accordance', 'korea', 'establishment', 'exchange', 'reason', 'protecting', 'historic', 'improvement', 'status', 'put', 'believe', 'ties', 'step', 'difficulties', 'prospects', 'sinojapanese']
efforts	['stability', 'korean', 'failed', 'issue', 'natural', '40', 'party', 'province', 'hongzhi', 'economic', 'largescale', 'shuibian', 'even', 'committee', 'seen', 'maintaining', 'opening', 'realize', 'sea', 'seek']	['issue', 'present', 'style', 'stressed', 'views', 'china', 'powell', 'peoples', 'april', 'high', 'cpc', 'zemin', 'wto', 'united', 'discussion', 'domestic', 'failed', 'form', 'issued', 'internal']	['organizations', 'ministry', 'arms', 'going', 'globalization', 'localities', 'close', 'allround', 'seen', 'defense', 'judicial', 'vice', 'develop', 'stability', 'officers', 'addition', 'direct', 'onechina', 'present', 'order']
war	['failed', 'principle', 'better', 'defense', 'parties', 'question', 'economic', 'course', 'due', 'united', 'election', 'structural', 'situation', 'financial', 'administrative', 'communist', 'bush', '40', 'addition', 'talks']	['failed', 'united', 'political', 'development', 'present', 'internal', 'exchanges', 'principle', 'cpc', 'far', 'members', 'style', 'issue', 'country', 'promote', 'addition', 'struggle', 'socialist', 'bush', 'whole']	['high', 'science', 'peace', 'promote', 'rule', 'production', 'find', 'official', 'constitution', 'role', 'industry', 'research', 'percent', 'national', 'largescale', 'territorial', 'news', '3', 'using', 'improvement']

word	FNN	RNN	LSTM
market	['financial', 'could', 'committee', 'failed', 'zemin', 'university', 'UNK', 'hoped', 'develop', 'peoples', 'among', 'really', 'natural', 'economy', 'communist', 'remarks', 'measures', 'progress', 'democratic', 'visiting']	['understanding', 'committee', 'peasants', 'leading', 'rights', 'history', 'present', 'another', 'UNK', 'next', 'without', 'could', 'socialist', 'form', 'department', 'brought', 'small', 'failed', 'cause', 'united']	['understanding', 'university', 'build', 'brought', 'zemin', 'building', 'regions', 'problems', 'hightech', 'hoped', 'addition', 'stressed', 'corruption', 'successfully', 'macao', 'front', 'short', 'step', 'conditions', 'hopes']
laws	['province', 'come', 'full', 'hard', 'failed', 'possible', 'committee', 'improvement', 'process', 'united', 'regard', 'second', 'projects', 'nuclear', 'environment', 'political', 'provincial', 'back', 'lies', 'socialist']	['failed', 'asia', 'get', 'future', 'regard', 'nuclear', 'judicial', 'strong', 'made', 'leading', 'working', 'promoting', 'course', 'comprehensively', 'two', 'strait', 'part', 'back', 'socialist', 'united']	['regional', 'develop', 'prospects', 'sea', 'clinton', 'competition', 'funds', 'adopt', 'process', '1999', 'maintained', 'organizations', 'really', 'pressure', 'direct', 'arms', 'plan', 'second', 'reports', 'localities']
dialogue	['necessary', 'today', 'plans', 'efforts', 'economic', 'defense', 'science', 'using', 'toward', 'developing', 'failed', 'however', 'better', 'afternoon', 'strengthening', 'seen', 'guiding', 'county', 'changes', 'enterprise']	['nearly', 'development', 'began', 'issue', 'united', 'largescale', 'invitation', 'first', 'developing', 'failed', 'basis', 'korean', 'success', 'common', 'south', 'present', 'find', 'course', 'minister', 'political']	['words', 'hand', 'august', 'largescale', 'share', 'thanks', 'korean', 'toward', 'research', 'industry', 'guidance', 'opening', 'using', 'development', 'view', 'say', 'study', 'today', 'wu', 'correct']
complete	['study', 'third', 'concerned', 'benefit', 'failed', 'make', 'quality', 'rural', '40', 'natural', 'views', 'constitution', 'policies', 'although', 'good', 'talks', 'still', 'back', 'therefore', 'reason']	['prc', 'failed', 'constitution', 'operation', 'reunification', 'members', 'bush', 'concerned', 'certain', 'lu', '10th', 'antichina', 'adopt', 'contacts', 'closely', 'zemin', 'socalled', 'third', 'ethnic', 'create']	['half', 'speech', 'build', 'person', 'provided', 'units', 'democracy', 'entry', 'scope', 'quality', 'always', '100', 'large', 'financial', 'really', '2', 'study', 'office', 'around', 'national']

word	FNN	RNN	LSTM
continued	['operation', 'failed', 'big', '40', 'domestic', 'course', 'addition', 'cadres', 'wei', 'firmly', 'vigorously', 'socialist', 'stressed', 'peoples', 'cpc', 'issue', 'responsible', 'handling', 'evil', 'basis']	['deputy', 'present', 'high', 'failed', 'power', 'members', 'kind', 'plan', 'efforts', 'province', 'wto', 'amount', 'united', 'april', 'views', 'theory', 'existing', 'changed', 'therefore', 'service']	['half', 'speech', 'build', 'person', 'provided', 'units', 'democracy', 'entry', 'scope', 'quality', 'always', '100', 'large', 'financial', 'really', '2', 'study', 'office', 'around', 'national']
visiting	['circles', 'forms', 'added', 'basis', 'sound', 'opportunities', 'advance', 'united', 'financial', 'cult', 'dialogue', 'responsibility', 'failed', 'current', 'korean', 'center', 'agreed', 'success', 'face', 'production']	['circles', 'last', 'development', 'ninth', 'hu', 'internal', 'political', 'responsibility', 'says', 'failed', 'difficult', 'shows', 'links', 'progress', 'members', 'resources', 'financial', 'president', 'management', 'zemin']	['october', 'able', 'ago', 'strengthening', 'economy', 'using', 'ninth', 'development', 'electronic', 'zemin', 'objective', 'office', 'circles', 'within', 'actual', 'past', 'internal', 'success', 'structural', 'used']